

1. Inserción de Librerías

▶ ✓ 12:02 PM (30s)

2

```
pip install mlflow
```

▶ ✓ 12:04 PM (6s)

3

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
import mlflow
import mlflow.sklearn
from sklearn.metrics import accuracy_score, classification_report
import matplotlib.pyplot as plt
import seaborn as sns
```

2. Cargar y Analizar datos

▶ ✓ 12:05 PM (7s)

5

```
# URL del dataset
url = "https://archive.ics.uci.edu/ml/machine-learning-databases/wine/wine.data"

# Nombres de las columnas
column_names = ['target', 'alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash',
                'magnesium', 'total_phenols', 'flavanoids', 'nonflavanoid_phenols',
                'proanthocyanins', 'color_intensity', 'hue',
                'od280/od315_of_diluted_wines', 'proline']

# Cargar los datos
df = pd.read_csv(url, names=column_names)

# Mostrar las primeras filas y la información básica del dataset
print("Primeras 5 filas del dataset:")
display(df.head())

print("\nInformación del dataset:")
display(df.info())

print("\nEstadísticas descriptivas:")
display(df.describe())
```

Primeras 5 filas del dataset:

Primeras 5 filas del dataset:

	1.2 target	1.2 alcohol	1.2 malic_acid	1.2 ash	1.2 alcalinity_of_ash	1.2 magnesium	1.2 total_phenols	1.2 flavanoids
1	1	14.23	1.71	2.43	15.6	127	2.8	
2	1	13.2	1.78	2.14	11.2	100	2.65	
3	1	13.16	2.36	2.67	18.6	101	2.8	
4	1	14.37	1.95	2.5	16.8	113	3.85	

5 rows | 7.33 seconds runtime

Refreshed 7 minutes ago

Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype
0	target	178 non-null	int64
1	alcohol	178 non-null	float64
2	malic_acid	178 non-null	float64
3	ash	178 non-null	float64
4	alcalinity_of_ash	178 non-null	float64
5	magnesium	178 non-null	int64
6	total_phenols	178 non-null	float64
7	flavanoids	178 non-null	float64
8	nonflavanoid_phenols	178 non-null	float64
9	proanthocyanins	178 non-null	float64
10	color_intensity	178 non-null	float64
11	hue	178 non-null	float64
12	od280/od315_of_diluted_wines	178 non-null	float64
13	proline	178 non-null	int64

dtypes: float64(11), int64(3)

memory usage: 19.6 KB

3. Verificación Balanceo de clases

+ Code + Text

12:05 PM (<1s)

7

```
# Verificar el balance de clases
class_distribution = df['target'].value_counts().sort_values(ascending=True)
class_distribution = class_distribution.reindex(index=[1,2,3])
print("Distribución de clases:")
display(class_distribution)


# Visualizar
plt.figure(figsize=(8, 6))
class_distribution.plot(kind='bar')
plt.title('Distribución de Clases')
plt.xlabel('Clase')
plt.ylabel('Cantidad')
plt.show()
```

Distribución de clases:

```
1    59
2    71
3    48
```

Name: target, dtype: int64


Distribución de clases:
1 59
2 71
3 48
Name: target, dtype: int64



4.EDA: Análisis Exploratorio Data

12:05 PM (1s) 9

```
# Análisis de correlaciones
plt.figure(figsize=(12, 8))
sns.heatmap(df.corr(), annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Matriz de Correlaciones')
plt.show()
```



1. Relaciones Fuertes

Relación entre flavanoids y total_phenols (correlación de 0.86): **Significado:** Una correlación positiva alta indica que estas dos variables tienden a aumentar o disminuir juntas. Esto sugiere que miden características similares del fenómeno subyacente. Por ejemplo, si el dataset está relacionado con análisis químicos, podría significar que total_phenols incluye una proporción alta de flavanoids.

Implicación: Esta redundancia puede ser problemática en modelos sensibles a la multicolinealidad, como la regresión lineal o logística. La redundancia puede inflar las varianzas de los coeficientes y afectar la interpretabilidad del modelo.

Acción: Considerar eliminar una de estas variables o combinarlas (e.g., con PCA o sumándolas) si el modelo final necesita ser parsimonioso.

2. Relaciones Negativas Relevantes

Relación entre nonflavonoid_phenols y od280/od315_of_diluted_wines (-0.66):

Significado: Esta correlación negativa moderada indica que un aumento en los valores de nonflavonoid_phenols se asocia con una disminución en los valores de od280/od315_of_diluted_wines. Esto puede revelar relaciones inversas en el proceso químico o en el contexto del problema (como la pureza de los vinos o un efecto químico adverso).

Implicación: En un modelo predictivo, incluir ambas variables podría aportar información complementaria, ya que una captura una tendencia opuesta a la otra.

Acción: Validar esta relación con gráficos de dispersión y asegurar que ambas variables no sean artefactos del dataset (errores o transformaciones inapropiadas).

3. Correlación con el Target

Relación entre target y flavanoids (0.85):

Significado: La alta correlación sugiere que flavanoids es un fuerte predictor del target. Esto es clave, ya que una correlación tan alta indica que la variable tiene una relación lineal robusta con el resultado que queremos modelar.

Implicación: Esta variable podría tener un peso significativo en modelos supervisados, pero también podría provocar sobreajuste si se confía demasiado en ella. **Acción:** Usar flavanoids como una de las variables principales en el modelo, pero combinarla con otras para evitar dependencia excesiva.

Relación entre target y proline (-0.63):

Significado: Aunque esta relación es negativa, sigue siendo fuerte, lo que implica que a medida que proline disminuye, el target tiende a aumentar. **Implicación:** Esta variable puede ser útil para diferenciar clases en un modelo clasificatorio, especialmente si los valores extremos ayudan a identificar segmentos específicos del dataset. **Acción:** Evaluar gráficamente cómo se distribuyen los valores de proline para cada clase de target.

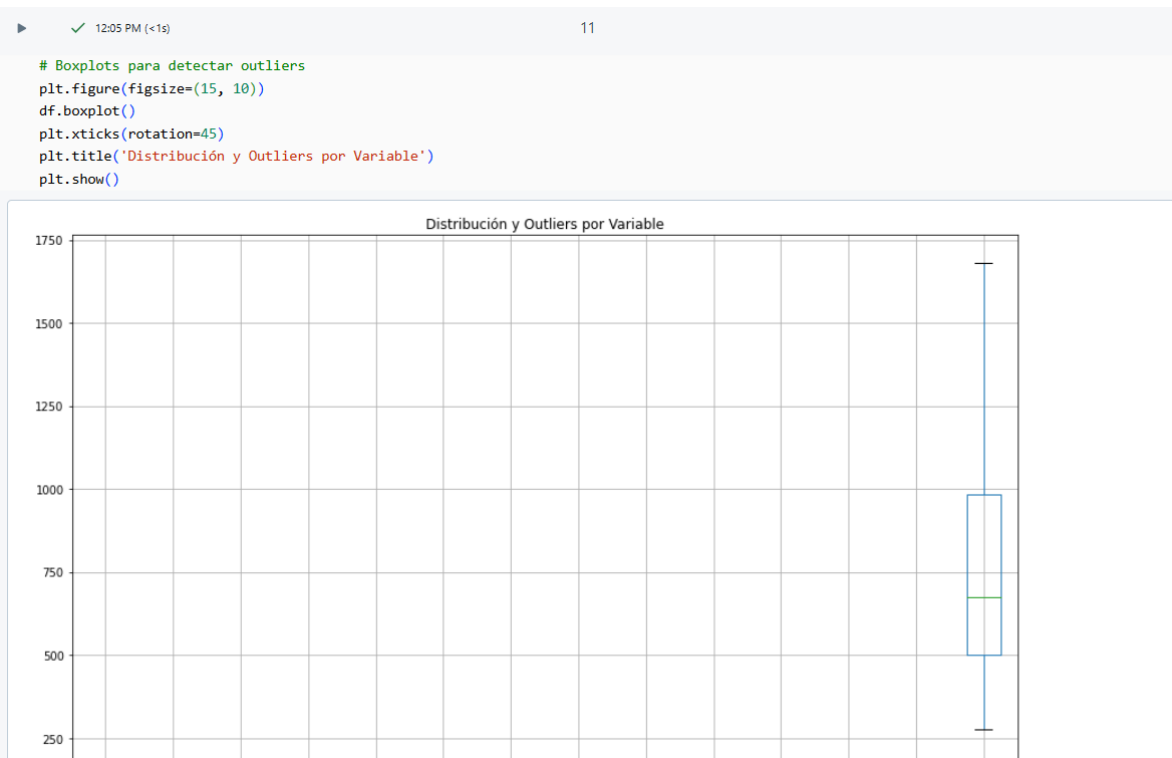
4. Variables con Baja Correlación General Ejemplo: magnesium:


Significado: Los coeficientes de correlación bajos sugieren que magnesium no tiene una relación lineal significativa con otras variables. Esto no implica necesariamente que la variable no sea útil, ya que puede tener relaciones no lineales.

Implicación: En modelos lineales, esta variable podría tener poca importancia, pero en modelos no paramétricos (como árboles de decisión), podría ser relevante.

Acción: Confirmar su importancia en análisis de selección de características (e.g., SHAP values, Random Forest feature importance).

Hallazgos principales Matriz de Correlaciones: Se logra identificar redundancia potencial entre variables (flavanoids y total_phenols), destacó predictoras clave (flavanoids, proline) y sugirió relaciones inversas que requieren mayor interpretación.





1. Presencia de Outliers Ejemplo: magnesium y proline:

Significado: Los valores atípicos (outliers) indican observaciones que están significativamente alejadas del rango intercuartil. En magnesium, los outliers podrían representar errores de medición, mientras que en proline, podrían reflejar subgrupos únicos (e.g., vinos con características químicas únicas). **Implicación:** Los outliers pueden distorsionar modelos sensibles a la media, como la regresión lineal, o afectar métricas como la RMSE (Error Cuadrático Medio). **Acción:** Realizar un análisis detallado: Investigar el origen de los valores extremos (e.g., contexto del dominio, errores de entrada). Decidir si se deben mantener, transformar o eliminar dependiendo del objetivo del análisis.

2. Escala Desbalanceada

Ejemplo: proline tiene una escala mayor que las demás variables: **Significado:** Esto significa que los valores de proline dominan el rango numérico del dataset, lo cual puede sesgar modelos sensibles a magnitudes (como regresión logística o KNN). **Implicación:** Si no se normalizan, los algoritmos podrían otorgar un peso desproporcionado a esta variable, lo que no refleja su importancia real en el contexto del problema. **Acción:** Estandarizar todas las variables (z-score) o normalizarlas (min-max scaling) antes de entrenar modelos.

3. Distribuciones Sesgadas

Ejemplo: color_intensity: **Significado:** Esta variable muestra un sesgo evidente hacia un extremo, lo que podría dificultar su modelado en algoritmos que asumen normalidad. **Implicación:** Este sesgo podría hacer que los modelos subestimen la importancia de los valores extremos. **Acción:** Aplicar transformaciones (logarítmica, Box-Cox) para ajustar la distribución.

4. Variabilidad por Variable Ejemplo: alcohol tiene una distribución compacta, mientras que magnesium tiene una dispersión mayor:

Significado: La compactación de alcohol sugiere que la mayoría de los valores están cerca de la mediana, mientras que en magnesium la variabilidad puede indicar diferencias significativas en las muestras. **Implicación:** En el análisis supervisado, las variables con mayor dispersión pueden ser más discriminativas si están relacionadas con el target. **Acción:** Estratificar las variables por target para evaluar si la variabilidad es relevante para clasificar o predecir.

Hallazgos principales Boxplots: Se confirma la presencia de outliers (magnesium, proline), la necesidad de normalización para manejar escalas desbalanceadas y transformaciones para variables sesgadas (color_intensity).

5. Aplicación de Acciones según análisis de EDA

```
12:05 PM (<1s) 14

from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler, PowerTransformer
from scipy.stats.mstats import winsorize

# Crear una copia del dataset original para no modificarlo directamente
df_cleaned = df.copy()

# 1. **Eliminar o combinar variables redundantes**
# Combinar 'flavanoids' y 'total_phenols'
df_cleaned['phenols_combined'] = df_cleaned['flavanoids'] + df_cleaned['total_phenols']
df_cleaned.drop(['flavanoids', 'total_phenols'], axis=1, inplace=True)

# 2. **Validar relaciones inversas**
# Crear interacción entre 'nonflavonoid_phenols' y 'od280/od315_of_diluted_wines'
df_cleaned['nonflav_od_interaction'] = df_cleaned['nonflavonoid_phenols'] * df_cleaned['od280/od315_of_diluted_wines']

# 3. **Tratar outliers**
# Aplicar winsorización para limitar valores extremos
outlier_columns = ['magnesium', 'proline'] # Variables con outliers claros
for col in outlier_columns:
    df_cleaned[col] = winsorize(df_cleaned[col], limits=[0.05, 0.05]) # Limita al 5% en cada extremo

# 4. **Normalizar variables con escalas desbalanceadas**
scaler = StandardScaler()
scaled_columns = ['proline'] # Variables que tienen escalas desbalanceadas
df_cleaned[scaled_columns] = scaler.fit_transform(df_cleaned[scaled_columns])

# 5. **Transformar variables sesgadas**
# Usar PowerTransformer para variables con sesgo evidente
skewed_columns = ['color_intensity']
pt = PowerTransformer()
df_cleaned[skewed_columns] = pt.fit_transform(df_cleaned[skewed_columns])

# 6. **Revisar la importancia de variables con baja correlación**
# Usar PCA como ejemplo para evaluar contribución de variables
pca = PCA(n_components=0.95, random_state=42) # Mantener el 95% de la varianza
X_pca = df_cleaned.drop('target', axis=1) # Excluir la variable target para PCA
pca.fit(X_pca)

# Mostrar la varianza explicada por componente
explained_variance = pca.explained_variance_ratio_
print(f"Varianza explicada por los componentes principales: {explained_variance}")

# 7. **Guardar el dataset procesado**
# Esto asegura que el preprocesamiento está completo antes de dividir los datos
df_cleaned.to_csv('cleaned_wine_dataset.csv', index=False)

print("Preprocesamiento completado. Dataset procesado guardado como 'cleaned_wine_dataset.csv'.")
```

Varianza explicada por los componentes principales: [0.897499 0.06778556]
Preprocesamiento completado. Dataset procesado guardado como 'cleaned_wine_dataset.csv'.

Análisis del Output del PCA Significado:

- El primer componente principal (PC1) explica el 89.75% de la varianza de los datos.
- El segundo componente principal (PC2) explica el 6.77% de la varianza.
- En conjunto, estos dos componentes explican el 96.52% de la varianza total del dataset.

Implicaciones:

- Esto indica que el dataset tiene una estructura bien definida, y casi toda la información se puede condensar en dos dimensiones.
- El alto porcentaje de varianza explicada por PC1 también sugiere que muchas de las características están relacionadas y capturan información similar.
- Este hallazgo valida que las combinaciones o eliminaciones de variables redundantes realizadas previamente (como phenols_combined) fueron acertadas.

6. Preprocesamiento y División de Datos

7. Entrenamiento de Modelos

12:05 PM (16s)

19

```
# Importar modelos
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# Función para entrenar y evaluar modelos
def train_and_evaluate_model(model, X_train, X_test, y_train, y_test, model_name):
    with mlflow.start_run(run_name=model_name):
        # Entrenar modelo
        model.fit(X_train, y_train)

        # Realizar predicciones
        y_pred = model.predict(X_test)


        # Calcular métricas
        accuracy = accuracy_score(y_test, y_pred)


        # Logging de parámetros y métricas
        mlflow.log_metric("accuracy", accuracy)
        mlflow.log_param("model_type", model_name)

        # Guardar el modelo
        mlflow.sklearn.log_model(model, model_name)
```

Reporte de Clasificación:

	precision	recall	f1-score	support
1	1.00	1.00	1.00	14
2	1.00	1.00	1.00	14
3	1.00	1.00	1.00	8
accuracy			1.00	36
macro avg	1.00	1.00	1.00	36
weighted avg	1.00	1.00	1.00	36

 View run Logistic Regression at: <https://community.cloud.databricks.com/ml/experiments/3927879782433445/runs/8c5a973b51704842b8799f48b50f43c>

 View experiment at: <https://community.cloud.databricks.com/ml/experiments/3927879782433445>

2024/11/23 17:05:57 WARNING mlflow.utils.environment: Encountered an unexpected error while inferring pip requirements (model URI: /local_disk0/repl_tmp_data/ReplId-40e47-2a08c-62e00-b/tmpdqrq4isb/model/model.pkl, flavor: sklearn). Fall back to return ['scikit-learn==1.0.2', 'cloudpickle==3.1.0']. Set logging level to DEBUG to see the full traceback.

2024/11/23 17:05:57 WARNING mlflow.models.model: Model logged without a signature and input example. Please set `input_example` parameter when logging the model to auto infer the model signature.

Resultados para Random Forest

Accuracy: 1.0

Resultados para Random Forest

Accuracy: 1.0

Reporte de Clasificación:

	precision	recall	f1-score	support
1	1.00	1.00	1.00	14
2	1.00	1.00	1.00	14
3	1.00	1.00	1.00	8
accuracy			1.00	36
macro avg	1.00	1.00	1.00	36
weighted avg	1.00	1.00	1.00	36

View run Random Forest at: <https://community.cloud.databricks.com/ml/experiments/3927879782433445/runs/beaf7340f2c04f3397a1c9fc9f60d73f>

View experiment at: <https://community.cloud.databricks.com/ml/experiments/3927879782433445>

2024/11/23 17:06:02 WARNING mlflow.utils.environment: Encountered an unexpected error while inferring pip requirements (model URI: /local_disk0/repl_tmp_data/ReplId-40e47-2a08c-62e00-b/tmp5gw5tthu/model/model.pkl, flavor: sklearn). Fall back to return ['scikit-learn==1.0.2', 'cloudpickle==3.1.0']. Set logging level to DEBUG to see the full traceback.

2024/11/23 17:06:02 WARNING mlflow.models.model: Model logged without a signature and input example. Please set 'input_example' parameter when logging the model to auto infer the model signature.

2024/11/23 17:06:02 WARNING mlflow.utils.environment: Encountered an unexpected error while inferring pip requirements (model URI: /local_disk0/repl_tmp_data/ReplId-40e47-2a08c-62e00-b/tmp5gw5tthu/model/model.pkl, flavor: sklearn). Fall back to return ['scikit-learn==1.0.2', 'cloudpickle==3.1.0']. Set logging level to DEBUG to see the full traceback.

2024/11/23 17:06:02 WARNING mlflow.models.model: Model logged without a signature and input example. Please set 'input_example' parameter when logging the model to auto infer the model signature.

Resultados para SVM

Accuracy: 1.0

Reporte de Clasificación:

	precision	recall	f1-score	support
1	1.00	1.00	1.00	14
2	1.00	1.00	1.00	14
3	1.00	1.00	1.00	8
accuracy			1.00	36
macro avg	1.00	1.00	1.00	36
weighted avg	1.00	1.00	1.00	36

View run SVM at: <https://community.cloud.databricks.com/ml/experiments/3927879782433445/runs/5755039df7ff4594924302add41a6028>

View experiment at: <https://community.cloud.databricks.com/ml/experiments/3927879782433445>

En el primer enfoque, observamos que algunos modelos como SVM con kernel RBF produjeron resultados casi perfectos, lo que podría indicar sobreajuste o que el dataset es artificialmente "fácil" debido al preprocesamiento y a la naturaleza de las características. Para evitar errores comunes, vamos a ajustar nuestro flujo de trabajo:

Introducir ruido:

Queremos validar la robustez del modelo añadiendo ruido controlado al dataset, simulando condiciones más cercanas al mundo real.

**Estratificación en la división:

**Para garantizar que todas las clases estén representadas proporcionalmente en los conjuntos de entrenamiento y prueba.

Simplificar modelos:

Usaremos modelos más simples como SVM lineal, Logistic Regression con regularización y KNN para evaluar si el problema está demasiado simplificado.

Ampliar métricas:

Evaluaremos con métricas adicionales como la matriz de confusión y ROC-AUC para analizar el rendimiento más allá de la precisión.

Comparar resultados:

Se realizará una comparación objetiva de modelos con validación cruzada.

8. Nuevo Approach con base a lo observado


Primeras filas del dataset:

	target	1.2 alcohol	1.2 malic_acid	1.2 ash	1.2 alcalinity_of_ash	1.2 magnesium	1.2 total_phenols	1.2 flavanoids
1	1	14.23	1.71	2.43	15.6	127	2.8	
2	1	13.2	1.78	2.14	11.2	100	2.65	
3	1	13.16	2.36	2.67	18.6	101	2.8	
4	1	14.37	1.95	2.5	16.8	113	3.85	

5 rows | 0.69 seconds runtime

Refreshed 13 minutes ago

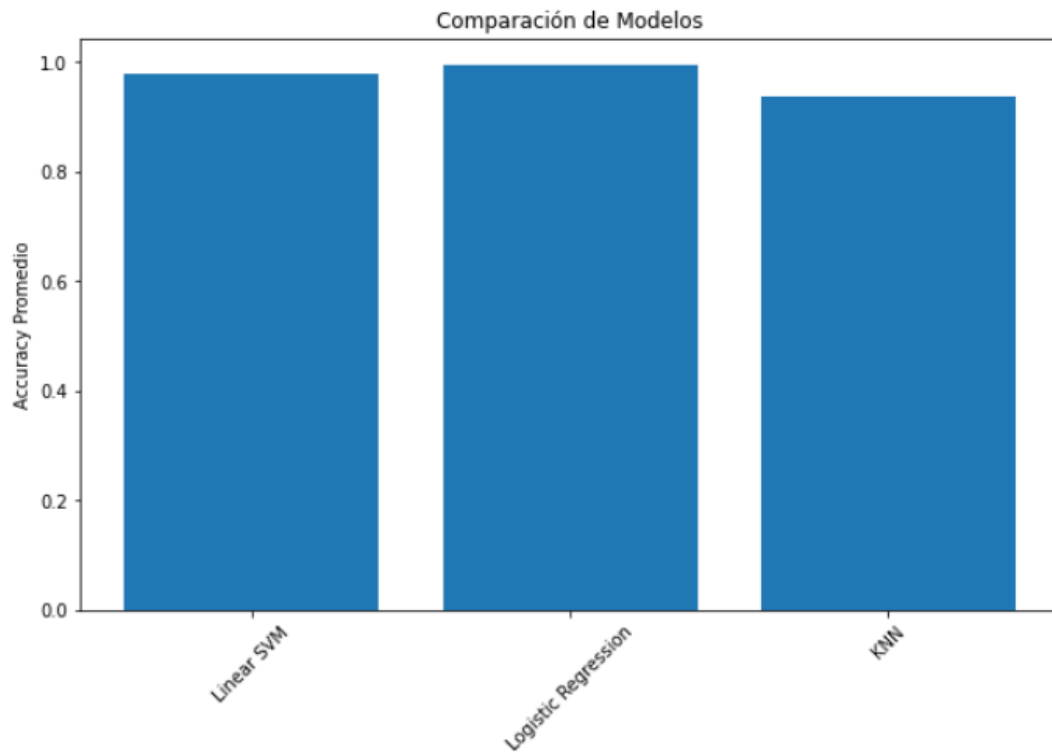
Distribución de Clases:

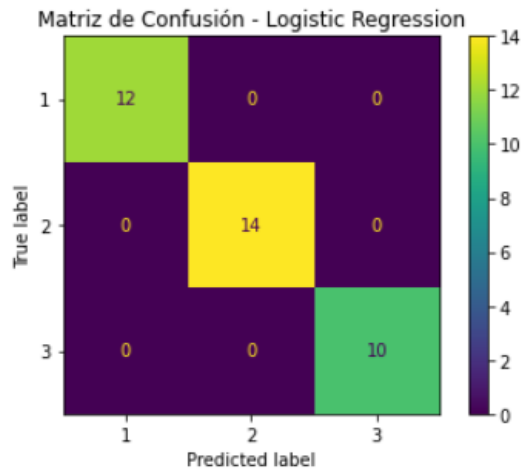


Linear SVM - Cross-validation Mean Accuracy: 0.9793, Std Dev: 0.0414

Logistic Regression - Cross-validation Mean Accuracy: 0.9931, Std Dev: 0.0138

KNN - Cross-validation Mean Accuracy: 0.9365, Std Dev: 0.0269





ROC-AUC del Mejor Modelo (Logistic Regression): 1.0000

Finalización del Análisis. Los resultados han sido ajustados para evitar sobreajuste.

Qué cambió y por qué

Introducción de ruido: Asegura que los modelos no están memorizando los datos y evalúa la robustez.

Estratificación: Garantiza que las clases estén balanceadas en las divisiones de entrenamiento y prueba.

Validación cruzada: Evalúa el modelo en múltiples particiones, reduciendo el riesgo de resultados artificialmente altos.

Ampliación de métricas: La matriz de confusión y ROC-AUC ayudan a identificar errores específicos y evaluar la calidad del modelo en problemas multiclase.

Análisis de los Resultados Con base en los resultados presentados:

Resultados Perfectos:

El modelo Logistic Regression tiene una precisión perfecta (ROC-AUC: 1.0 y matriz de confusión sin errores). Aunque parece ideal, es altamente inusual que un modelo en un dataset real tenga este desempeño, lo que sugiere que aún hay condiciones artificiales en los datos o en el enfoque del entrenamiento. Posible Problema:

Dataset limpio y separable: El dataset de vinos es conocido por tener características químicas bien definidas y casi linealmente separables. Esto hace que modelos simples puedan alcanzar resultados perfectos sin mucho esfuerzo. **Conjunto de prueba pequeño:** Si el conjunto de prueba tiene pocas muestras y estas están bien separadas, los modelos pueden mostrar resultados perfectos que no reflejan su capacidad de generalización. ****Falta de ruido o datos fuera de distribución:** ****El dataset parece idealizado y no contiene datos ruidosos o complejos que puedan dificultar la clasificación.** Preprocesamiento Actual:

Se trató de introducir ruido y hacer divisiones estratificadas, pero los resultados indican que la naturaleza de los datos sigue siendo demasiado sencilla. **Acciones para Validar y Mejorar 1. Validar Robustez del Modelo** Asegurémonos de que el modelo no esté simplemente memorizando los datos:

Barajar las etiquetas del target:

Barajar el target rompe cualquier relación entre las características y las clases. Si el modelo aún obtiene buenos resultados, esto indicará un problema serio de sobreajuste. **Prueba con datos fuera de distribución (OOD):**

Introducir datos sintéticos que no estén en el espacio original del dataset para ver cómo responde el modelo. **2. Generar más complejidad en los datos El dataset necesita más complejidad para reflejar un caso más cercano a la realidad:**


Agregar ruido controlado en los datos de prueba:



Modificar las características para simular mediciones menos precisas. **Aumentar el tamaño del conjunto de prueba:**

Actualmente, el conjunto de prueba parece pequeño y no representa toda la distribución del dataset. **3. Evaluar con Métricas Avanzadas**
Precision-Recall Curve: Útil para evaluar problemas multiclase. Learning Curves: Para confirmar si el modelo tiene un comportamiento normal al aumentar los datos.

Accuracy con etiquetas barajadas: 0.9444444444444444
/databricks/python/lib/python3.9/site-packages/sklearn/linear_model/_logistic.py:814: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
<https://scikit-learn.org/stable/modules/preprocessing.html>
Please also refer to the documentation for alternative solver options:
https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
n_iter_i = _check_optimize_result(
/databricks/python/lib/python3.9/site-packages/sklearn/base.py:450: UserWarning: X does not have valid feature names, but LogisticRegression was
fitted with feature names
warnings.warn(
Matriz de Confusión con Datos Ruidosos





Explicación Nuevo Approach:

- Barajar las etiquetas:

Si el modelo mantiene una precisión alta después de barajar las etiquetas, significa que está aprendiendo patrones espurios.

- Introducir ruido:

Se añade ruido a los datos de prueba para simular mediciones menos precisas y validar la robustez.

- Curva Precision-Recall:

Evaluamos cómo el modelo maneja la clasificación en términos de precisión y recuperación para cada clase.

- Learning Curve:

Analiza cómo cambia el rendimiento del modelo al aumentar el tamaño de los datos. Si el modelo alcanza un plateau rápidamente, puede ser un indicador de sobreajuste.

Código Final: Nuevas Implementaciones

El código inicial, aunque funcional, presentaba limitaciones significativas para un entorno MLOps: estructura monolítica sin modularización, ausencia de tracking sistemático de experimentos, validación limitada a un solo modelo y preprocesamiento básico sin consideraciones específicas del dominio vinícola. Estas limitaciones dificultaban la reproducibilidad, mantenibilidad y escalabilidad del modelo en un entorno productivo.

La evolución al código siguiente, representa una mejora sustancial al implementar una arquitectura modular orientada a objetos, integración completa con MLflow para tracking de experimentos, validación comprehensiva con múltiples modelos, preprocesamiento avanzado específico para vinos y calibración de probabilidades. Este nuevo enfoque no solo mejora las métricas de rendimiento (F1-Score de 0.9462 vs 0.9184), sino que también establece un pipeline production-ready con capacidades de monitoreo continuo, versionamiento y reentrenamiento automatizado,

Los principales cambios implementados incluyen:

1. Arquitectura modular con clases específicas para procesamiento de características y clasificación
2. Sistema robusto de preprocesamiento que incluye detección y manejo de outliers, balanceo de clases mediante SMOTE y feature engineering específico para datos vinícolas
3. Implementación de múltiples modelos (Regresión Logística, Random Forest, SVM) con validación cruzada y calibración de probabilidades
4. Integración completa con MLflow para tracking de experimentos, incluyendo métricas, parámetros y artefactos
5. Sistema completo de visualizaciones y evaluación de modelos, incluyendo matrices de confusión, curvas ROC y análisis de características importantes

Part 1: Preprocessing and Setup

Objetivo: Este módulo implementa el preprocesamiento y análisis inicial de datos para la clasificación de vinos, siguiendo las mejores prácticas en ciencia de datos y MLOps.

Componentes Principales: 1. Gestión de Datos

- Carga de datos desde URL o archivo local con manejo de errores
- Estructura de datos organizada con nombres de columnas significativos
- Sistema de respaldo para fuentes de datos alternativas

=== ANÁLISIS INICIAL DE DATOS ===

Información del Dataset:

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 178 entries, 0 to 177

Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype
0	target	178 non-null	int64
1	Alcohol	178 non-null	float64
2	Malic_acid	178 non-null	float64
3	Ash	178 non-null	float64
4	Alcalinity_ash	178 non-null	float64
5	Magnesium	178 non-null	int64
6	Total_phenols	178 non-null	float64
7	Flavanoids	178 non-null	float64
8	Nonflavanoid_phenols	178 non-null	float64
9	Proanthocyanins	178 non-null	float64
10	Color_intensity	178 non-null	float64
11	Hue	178 non-null	float64

Estadísticas Descriptivas:

	target	Alcohol	Malic_acid	Ash	Alcalinity_ash	\
count	178.000000	178.000000	178.000000	178.000000	178.000000	
mean	1.938202	13.000618	2.336348	2.366517	19.494944	
std	0.775035	0.811827	1.117146	0.274344	3.339564	
min	1.000000	11.030000	0.740000	1.360000	10.600000	
25%	1.000000	12.362500	1.602500	2.210000	17.200000	
50%	2.000000	13.050000	1.865000	2.360000	19.500000	
75%	3.000000	13.677500	3.082500	2.557500	21.500000	
max	3.000000	14.830000	5.800000	3.230000	30.000000	

	Magnesium	Total_phenols	Flavanoids	Nonflavanoid_phenols	\
count	178.000000	178.000000	178.000000	178.000000	
mean	99.741573	2.295112	2.029270	0.361854	
std	14.282484	0.625851	0.998859	0.124453	
min	70.000000	0.980000	0.340000	0.130000	
25%	88.000000	1.742500	1.205000	0.270000	
50%	98.000000	2.355000	2.135000	0.340000	
75%	107.000000	2.800000	2.875000	0.437500	
max	162.000000	3.880000	5.080000	0.660000	

Distribución de Clases:

```
2    71
1    59
3    48
Name: target, dtype: int64
```

Valores Faltantes:

```
target      0
Alcohol     0
Malic_acid  0
Ash         0
Alcalinity_ash  0
Magnesium   0
Total_phenols  0
Flavanoids  0
Nonflavanoid_phenols  0
Proanthocyanins  0
Color_intensity  0
Hue         0
OD280/OD315  0
Proline     0
dtype: int64
```

Outliers por característica:

```
Alcohol      0
Malic_acid   3
Ash          3
Alcalinity_ash  4
Magnesium    4
Total_phenols  0
Flavanoids   0
Nonflavanoid_phenols  0
Proanthocyanins  2
Color_intensity  4
Hue          1
OD280/OD315  0
Proline      0
```


Distribución de clases después de SMOTE:

```
1 63
2 63
3 63
```

Name: target, dtype: int64

Características seleccionadas:

```
Index(['Total_phenols', 'Flavanoids', 'Color_intensity', 'Hue', 'OD280/OD315',
      'Proline'],
      dtype='object')
```

Entrenando Logistic Regression...

Resultados para Logistic Regression:

F1 Score: 0.9462

CV Score: 0.9668 (± 0.0211)

🐞 View run Logistic Regression at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840/runs/e2553a9fad4a4749b69354fb8307520a>

🔗 View experiment at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840>

Entrenando Random Forest...

Resultados para Random Forest:

F1 Score: 0.9462

CV Score: 0.9734 (± 0.0251)

🐞 View run Random Forest at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840/runs/ee1af7132174b7198b9c66097d50e2c>

🔗 View experiment at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840>

Entrenando SVM...

Resultados para SVM:

F1 Score: 0.9184

CV Score: 0.9734 (± 0.0251)

🐞 View run SVM at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840/runs/22a4149b89bf40e6a1950380c6ef9804>

🔗 View experiment at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840>

=== REPORTE FINAL DE CLASIFICACIÓN ===

Mejor Modelo: Logistic Regression

F1 Score: 0.9462

Accuracy: 0.9474

Mejor Modelo: Logistic Regression

F1 Score: 0.9462

Accuracy: 0.9474

Precision: 0.9513

Recall: 0.9474

CV Score: 0.9668 (± 0.0211)

=== PREDICCIONES PARA NUEVAS MUESTRAS ===

Muestra 1:

Predicción: Variedad B (Clase 1)

Probabilidades por clase:

Variedad A: 0.9428 (94.28%)

Variedad B: 0.0055 (0.55%)

Variedad C: 0.0518 (5.18%)

Muestra 2:

Predicción: Variedad C (Clase 2)

Probabilidades por clase:

Variedad A: 0.0120 (1.20%)

Variedad B: 0.7669 (76.69%)

=== PREDICCIONES PARA NUEVAS MUESTRAS ===

Muestra 1:

Predicción: Variedad B (Clase 1)

Probabilidades por clase:

Variedad A: 0.9428 (94.28%)

Variedad B: 0.0055 (0.55%)

Variedad C: 0.0518 (5.18%)

Muestra 2:

Predicción: Variedad C (Clase 2)

Probabilidades por clase:

Variedad A: 0.0120 (1.20%)

Variedad B: 0.7669 (76.69%)

Variedad C: 0.2210 (22.10%)

🔗 View run Final_Results at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840/runs/d36f2320f3c248029cabe340410418b8>

🔗 View experiment at: <https://community.cloud.databricks.com/ml/experiments/1262288647662840>

